

Universidad del Valle de Guatemala

Facultad de Ingeniería

Departamento de Computación

Data Science

1966

UNIVERSIDAD

GUATEMALA

LABORATORIO VII

PERFILES Y SALARIO DE LA POBLACIÓN
ASALARIADA

DEL VALLE DE

André Emilio Pivaral López — 23574

Excelencia que trasciende

Catedrático: Boris Fernando Becerra Peláez

Sección: 30

Nueva Guatemala de la Asunción, 27 de septiembre de 2026

Índice

1. Resumen	1
2. Introducción	1
3. Datos y preparación	2
3.1. Fuente y armonización de los archivos	2
3.2. Faltantes y población analítica	2
3.3. Unicidad y estructura longitudinal	3
4. Análisis exploratorio	4
4.1. Estadística descriptiva	4
4.2. Distribución del salario	4
4.3. Diferencias entre grupos y trimestres	5
5. Relaciones entre variables numéricas	6
6. Segmentación de perfiles	7
6.1. Espacios de agrupamiento y selección de K	7
6.2. Perfiles identificados	8
7. Modelado supervisado	10
7.1. Diseño experimental	10
7.2. Regresión lineal	10
7.3. Random Forest	12
7.4. Evaluación final en 2026	13
8. Análisis de errores	13
8.1. Salario real frente a predicho y residuos	13
8.2. Error por nivel educativo y por dominio	14
8.3. Error según el percentil del salario	15
9. Discusión	16
10. Conclusiones	17

1. Resumen

Este informe documenta el análisis del salario mensual de la población asalariada de Guatemala con las bases de Personas de la Encuesta Nacional de Empleo e Ingresos Continua. Se integraron cinco cortes trimestrales, cuatro de 2025 para desarrollo y uno de 2026 para la prueba final, y todo el procesamiento se realizó con Spark 3.5 y la API de DataFrames de pyspark.ml. Tras armonizar los archivos y aplicar los criterios de la población analítica se obtuvieron 53,025 registros de asalariados en 2025 y 13,258 en 2026. El salario resultó fuertemente asimétrico, con media de Q3,421.68 y mediana de Q3,000, y se asoció mucho más con el nivel educativo, la categoría ocupacional y el dominio que con la edad, la antigüedad o la jornada. La segmentación con KMeans identificó cinco perfiles definidos por la etapa de la trayectoria laboral y la jornada. En la predicción del salario, un Random Forest alcanzó en 2026 un R^2 de 0.542 y un RMSE de Q1,940.30, frente a 0.431 y Q2,163.75 de la regresión lineal. Ambos modelos subestiman de forma sistemática los salarios altos, y el 5 % de salarios más altos concentra cerca del 60 % del error cuadrático.

2. Introducción

El estudio de los salarios permite identificar diferencias entre grupos de trabajadores, comprender su relación con la educación y las condiciones laborales y generar evidencia para el análisis del mercado de trabajo. Este laboratorio responde dos preguntas. La primera es qué perfiles de trabajadores asalariados pueden identificarse según su edad, su antigüedad y su jornada habitual. La segunda es qué tan bien puede estimarse el salario mensual de una persona asalariada a partir de seis características personales y laborales observadas: edad, antigüedad, horas semanales habituales, nivel educativo, categoría ocupacional y dominio.

Los datos provienen de la Encuesta Nacional de Empleo e Ingresos Continua del Instituto Nacional de Estadística (2026). Cada registro corresponde a una persona observada en un trimestre, y la encuesta tiene un diseño longitudinal con rotación, por lo que una misma persona puede aparecer en varios cortes. Los cuatro trimestres de 2025 se usaron para el desarrollo de los modelos y el primer trimestre de 2026 se reservó para su evaluación final. El procesamiento se realizó con Spark y MLlib (The Apache Software Foundation, 2024). Los resultados describen a los registros analizados sin ponderar, no constituyen estimaciones oficiales de la población del país y las asociaciones encontradas no implican causalidad.

3. Datos y preparación

3.1. Fuente y armonización de los archivos

Se utilizaron las bases de Personas de los trimestres I, II, III y IV de 2025 y del trimestre I de 2026, junto con sus diccionarios de datos. La Tabla 1 resume su tamaño. Los cinco diccionarios asignan las mismas etiquetas a los 21 códigos revisados de nivel educativo, categoría ocupacional, dominio y condición de ocupación, por lo que un único catálogo sirvió para validar todos los cortes.

Tabla 1: Archivos de la base de Personas utilizados y registros retenidos tras los filtros

Corte	Uso	Registros	Columnas	Retenidos	Retención
2025T1	Entrenamiento	51,588	270	13,419	26.01 %
2025T2	Entrenamiento	51,167	270	13,492	26.37 %
2025T3	Entrenamiento	51,583	270	13,450	26.07 %
2025T4	Validación	49,338	302	12,664	25.67 %
2026T1	Prueba final	49,843	270	13,258	26.60 %
Total 2025	Desarrollo	203,676		53,025	26.03 %

La armonización enfrentó tres problemas de origen. El corte IV de 2025 tiene 302 columnas en lugar de 270, agrega 42 variables de las secciones P07 y P08 y elimina 10, de modo que casi todas las variables cambian de posición; el salario, por ejemplo, pasa de la columna 105 a la 98. Por esa razón los archivos no pueden apilarse por posición y se unieron por nombre de columna con `unionByName`. El corte II de 2025 entrega los códigos categóricos como texto, mientras que los demás los entregan como enteros, lo que se resolvió leyendo cada variable por su nombre y convirtiéndola a un tipo único dentro de un esquema explícito de Spark. Finalmente, la columna `TRIMESTRE` no identifica el trimestre calendario: vale 2, 4, 5 y 6 en los cortes I, III y IV de 2025 y I de 2026, y el corte II de 2025 mezcla el valor 3 con 175 registros de valor 2. Por eso la procedencia se asignó a partir del archivo leído, conservando `TRIMESTRE` sin cambios para auditoría.

3.2. Faltantes y población analítica

Antes de filtrar, el salario falta en el 73.97 % de los registros de 2025 y la categoría ocupacional, la antigüedad y las horas en el 56.69 %. Estos vacíos son estructurales. Los 115,454 vacíos de las variables de empleo corresponden a personas no ocupadas, a quienes no se aplica esa sección del cuestionario; el nivel educativo solo falta en

menores de 7 años, que es la edad desde la que se pregunta; y el salario existe exactamente para las cuatro categorías asalariadas y para ninguna otra. Un dato ausente porque la pregunta no corresponde es una respuesta correcta que se resuelve delimitando la población, mientras que una respuesta no registrada es información perdida que puede sesgar el análisis. En estas bases prácticamente todos los faltantes son del primer tipo.

La población analítica se definió con ocho criterios aplicados siempre en el mismo orden, cuyo efecto se resume en la Tabla 2. Solo los tres criterios que definen la población excluyen registros. Los cinco restantes, que verifican el salario positivo y la consistencia de la antigüedad y de las horas, no excluyen ninguno, lo que indica que la base publicada ya cumple esas reglas. No se imputó el salario ni se eliminaron valores extremos.

Tabla 2: Registros excluidos en cada paso de la cadena de filtros

Paso	Criterio	2025	2026T1
0	Registros originales	203,676	49,843
1	Edad finita y mayor o igual a 15	62,886	14,803
2	Persona ocupada	52,568	13,306
3	Categoría ocupacional asalariada 1, 2, 3 o 4	35,197	8,476
4	Salario numérico, finito y mayor que cero	0	0
5	Antigüedad en años no negativa	0	0
6	Meses de antigüedad enteros entre 0 y 11	0	0
7	Antigüedad menor o igual a la edad	0	0
8	Horas mayores que 0 y hasta 168	0	0
Población analítica		53,025	13,258

3.3. Unicidad y estructura longitudinal

La combinación de periodo de archivo, número de hogar y número de persona resultó única en todos los conjuntos, antes y después de filtrar, por lo que no hubo repeticiones exactas ni registros en conflicto. Entre cortes, en cambio, 15,406 de las 26,709 personas de la población analítica de 2025 aparecen en dos o más trimestres y aportan el 78.7 % de los registros, y en el 99.6 % de ellas la edad cambia cero o un año entre la primera y la última aparición. Estas repeticiones no son duplicados, porque la unidad de observación es la persona en un período y cada visita es una medición válida. Por la misma razón, y porque cada registro representa a un número distinto de personas según el factor de expansión, el número de registros no equivale al número de trabajadores del país. El factor se conservó en los datos, pero el análisis

es no ponderado.

4. Análisis exploratorio

4.1. Estadística descriptiva

La Tabla 3 resume las variables numéricas de la población analítica de 2025. La Figura 1 muestra que el empleo privado reúne el 54.1 % de los registros, seguido por jornaleros con 26.1 %, gobierno con 12.4 % y servicio doméstico con 7.4 %. En educación predominan el diversificado y la primaria, y cuatro de cada cinco registros son urbanos.

Tabla 3: Estadísticos de las variables numéricas, población analítica de 2025

Variable	Media	Mediana	Desv.	Mín.	Máx.	p25	p75	p95
Salario mensual, Q	3,421.68	3,000	2,902.11	1	99,000	1,800	4,000	8,000
Edad, años	35.19	33	13.52	15	89	24	44	61
Antigüedad, años	5.56	2	7.83	0	70	0.5	7	22
Horas por semana	46.31	45	18.63	1	126	40	55	80




Figura 1: Distribución de los registros de 2025 por categoría ocupacional, nivel educativo y dominio

4.2. Distribución del salario

El salario presenta una distribución fuertemente asimétrica a la derecha, con asimetría de 6.0 y curtosis en exceso de 103.5, como muestra la Figura 2. La mayoría de los salarios se encuentra entre Q1,000 y Q5,000, el percentil 99 es Q15,000 y el máximo llega a Q99,000. La media supera a la mediana en Q421.68, un 14.1 %, y solo

el 43.7 % de los registros gana más que la media, porque los salarios altos elevan el promedio sin mover la mediana. En escala logarítmica la distribución se vuelve casi simétrica. El máximo corresponde a una misma persona reportada con ese monto en tres cortes consecutivos, por lo que se conservó como una respuesta consistente.




Figura 2: Distribución del salario mensual de 2025 en escala original y en escala logarítmica

4.3. Diferencias entre grupos y trimestres

El salario mediano crece con cada nivel educativo, desde Q1,500 sin educación hasta Q5,000 con educación superior, Q10,000 con maestría y Q12,000 con doctorado, y varía entre categorías ocupacionales desde Q1,000 en servicio doméstico hasta Q5,000 en el empleo público, como muestra la Figura 3. Por dominio descende de Q3,700 en el área metropolitana a Q2,000 en el área rural. La Figura 4 muestra que el tamaño de la población analítica es estable entre cortes y que el salario mediano sube de Q3,000 a Q3,200 a partir del tercer trimestre de 2025, mientras la media crece de Q3,315.6 a Q3,565.8 en el corte de prueba.




Figura 3: Salario mediano y rango intercuartílico por nivel educativo y por categoría ocupacional




Figura 4: Tamaño de la población analítica y salario mediano y medio por corte

5. Relaciones entre variables numéricas

La correlación de Pearson se calculó con `Correlation.corr` sobre los 53,025 registros elegibles de 2025 y se complementó con la correlación de Spearman, menos sensible a la asimetría del salario. La Figura 5 muestra que ninguna variable se asocia fuertemente con el salario: la antigüedad alcanza 0.180, la edad 0.147 y las horas 0.076, de modo que ninguna explica por sí sola más del 3.3% de su variación. La asociación más fuerte es entre edad y antigüedad, con 0.487, ya que la antigüedad solo se acumula con los años. La Figura 6 muestra que esta relación es triangular: la antigüedad nunca supera la edad menos los años previos al empleo, pero una persona mayor puede tener cualquier antigüedad menor si cambió de trabajo.




Figura 5: Correlación de Pearson y de Spearman entre salario, edad, antigüedad y horas, 2025




Figura 6: Relación entre edad y antigüedad y entre horas, antigüedad y salario, muestra de 5,000 registros

6. Segmentación de perfiles

6.1. Espacios de agrupamiento y selección de K

Se aplicó KMeans con la inicialización paralela implementada en Spark (Bahmani et al., 2012) sobre tres espacios estandarizados: edad, antigüedad y horas sin salario, el mismo espacio con el salario en quetzales y el mismo espacio con el logaritmo del salario. Cada combinación con K de 2 a 5 se evaluó con la inercia, con el coeficiente de silueta (Rousseeuw, 1987) calculado sobre todos los registros y con el tamaño del menor clúster, como resume la Tabla 4.

Tabla 4: Coeficiente de silueta y tamaño del menor clúster por espacio y valor de K

K	Sin salario		Con salario		Logaritmo del salario	
	Silueta	Menor	Silueta	Menor	Silueta	Menor
2	0.5545	27.54 %	0.5146	27.03 %	0.4702	28.27 %
3	0.4716	19.07 %	0.3371	16.76 %	0.4753	17.60 %
4	0.4760	12.95 %	0.3753	4.40 %	0.3723	11.43 %
5	0.4839	11.65 %	0.4137	3.98 %	0.3867	10.66 %

Incluir el salario no resultó conveniente. En quetzales, la silueta cae a 0.337 con K igual a 3 y, con K igual a 4 y 5, aparece un clúster de menos del 5% de los registros dedicado a aislar salarios extremos. El logaritmo corrige ese problema, pero no supera al espacio sin salario cuando K es 4 o 5. Además, si el salario forma los grupos, compararlo después entre perfiles se vuelve circular, por lo que se utilizó como descriptor.

Dentro del espacio sin salario, el número de grupos se eligió con un criterio de tres

condiciones: ningún clúster con menos del 5% de los registros, cada variable debe separar al menos un grupo en una desviación estándar o más, y entre los valores admisibles se elige la mayor silueta. K igual a 2 tiene la mayor silueta, 0.555, pero no separa los grupos por jornada. Entre los admisibles, la silueta crece con K y el criterio selecciona K igual a 5, con silueta de 0.484, como se observa en la Figura 7. Una silueta cercana a 0.48 indica una estructura moderada, en la que los perfiles describen regiones de un continuo más que grupos aislados.




Figura 7: Criterio de codo y coeficiente de silueta por espacio de agrupamiento y valor de K

6.2. Perfiles identificados

La Tabla 5 y las Figuras 8 y 9 describen los cinco perfiles. El perfil 1 reúne a jóvenes con jornada completa, en su mayoría del empleo privado. El perfil 2 agrupa a trabajadores con jornada parcial, con fuerte presencia de jornaleros, servicio doméstico y área rural, y tiene el salario mediano más bajo. El perfil 3 corresponde a jóvenes con jornada extendida en el empleo privado, cuyo salario no supera al del perfil 1 pese a trabajar muchas más horas. El perfil 4 reúne a adultos con baja antigüedad y el perfil educativo más bajo, y el perfil 5 a trabajadores de larga permanencia, con mayor peso del empleo público y de la educación superior, que es el mejor remunerado. La jornada parcial y la permanencia prolongada son los rasgos que más cambian el salario típico, mientras que la edad por sí sola casi no lo modifica.

Tabla 5: Perfiles de asalariados obtenidos con KMeans, población analítica de 2025

Perfil	Descripción	Registros	Edad media	Antigüedad mediana	Horas mediana	Salario mediano	Salario medio
1	Jóvenes con jornada completa	22,716	26.3	1.5	48	3,200	3,370.9
2	Jornada parcial	6,502	29.7	1.2	21	1,200	1,944.2
3	Jornada extendida	6,177	31.1	2.0	76	3,000	3,266.7
4	Adultos con baja antigüedad	11,006	50.0	3.0	44	3,200	3,707.0
5	Larga permanencia	6,624	50.2	20.0	40	3,800	4,716.5




Figura 8: Centroides de los perfiles, color en desviaciones estándar y texto en promedio original




Figura 9: Distribución de edad, antigüedad, horas y salario por perfil sobre todos los registros

7. Modelado supervisado

7.1. Diseño experimental

El objetivo fue estimar el salario mensual del período observado con seis predictores: edad, antigüedad, horas semanales, nivel educativo, categoría ocupacional y dominio. Las particiones siguieron el orden temporal, como resume la Tabla 6. Ninguna categoría de validación o prueba falta en los datos de entrenamiento. Por el diseño longitudinal, el 69.7 % de los registros de validación y el 58.2 % de los de prueba pertenecen a personas ya observadas en los datos de entrenamiento, por lo que las métricas pueden resultar algo optimistas frente a personas completamente nuevas.

Tabla 6: Particiones temporales utilizadas en el modelado

Conjunto	Cortes	Registros	Salario medio	Salario mediano
Entrenamiento	2025T1 a 2025T3	40,361	3,383.1	3,000
Validación	2025T4	12,664	3,544.6	3,200
Entrenamiento final	2025T1 a 2025T4	53,025	3,421.7	3,000
Prueba	2026T1	13,258	3,565.8	3,200

Ambos algoritmos compartieron el mismo preprocesamiento dentro de un pipeline de `pyspark.ml`. `StringIndexer` indexó las variables categóricas por frecuencia ascendente, de modo que `OneHotEncoder` descartó la categoría más frecuente, que quedó como referencia: diversificado, empleo privado y área urbana metropolitana. `VectorAssembler` combinó las tres variables numéricas con las categóricas codificadas. Todos los componentes se ajustaron solo con los datos de entrenamiento. Como modelo de referencia se utilizó la predicción constante del salario medio de entrenamiento, y las configuraciones se compararon por el RMSE en el conjunto de validación.

7.2. Regresión lineal

La regresión lineal se ajustó con la estandarización interna de los predictores y siete configuraciones de regularización, que incluyen Ridge, Lasso y Elastic Net (Zou y Hastie, 2005). La Tabla 7 muestra que la regresión sin regularización obtuvo el menor RMSE de validación, Q2,186.42, frente a Q2,889.57 de la referencia, una reducción del 24.3 %, con un R^2 de 0.426. Las penalizaciones fuertes empeoraron el RMSE, ya que con 40,361 registros y 15 coeficientes no existe sobreajuste que corregir, aunque redujeron ligeramente el MAE al acercar las predicciones al centro de la distribución.

Tabla 7: Configuraciones de regresión lineal evaluadas en 2025T4

Tipo	regParam	elasticNetParam	MAE	RMSE	R^2	RMSE entren.
Referencia			1,672.50	2,889.57	-0.0031	
Sin regularización	0	0	1,210.14	2,186.42	0.4257	2,245.29
Ridge	10	0	1,209.63	2,186.56	0.4256	2,245.30
Ridge	100	0	1,205.56	2,188.19	0.4247	2,245.71
Ridge	1,000	0	1,199.23	2,223.37	0.4061	2,271.58
Lasso	10	1	1,205.63	2,187.45	0.4251	2,245.58
Lasso	100	1	1,205.47	2,221.11	0.4073	2,272.39
Elastic Net	100	0.5	1,196.60	2,199.10	0.4190	2,253.58

Los coeficientes del modelo elegido, en la Tabla 8, indican que, manteniendo lo demás constante, cada año de edad suma Q20.43, cada año de antigüedad Q23.37 y cada hora semanal Q16.17. El efecto de la educación es claramente no lineal, con un salto grande en el posgrado, y el servicio doméstico es la categoría con mayor penalización salarial frente al empleo privado.

Tabla 8: Coeficientes de la regresión lineal elegida, en quetzales frente a la categoría de referencia

Variable	Categoría o unidad	Coeficiente
Edad	Por año	20.43
Antigüedad	Por año	23.37
Horas semanales	Por hora	16.17
Nivel educativo	Ninguno	-1,333.40
	Preprimaria	-1,049.07
	Primaria	-836.43
	Básico	-631.22
	Superior	1,694.39
	Maestría	6,780.56
	Doctorado	8,619.70
Categoría ocupacional	Empleado de gobierno	1,173.60
	Jornalero o peón	-858.48
	Servicio doméstico	-1,664.57
Dominio	Resto urbano	-558.56
	Rural nacional	-568.01

7.3. Random Forest

El Random Forest (Breiman, 2001) se entrenó con el mismo preprocesamiento, sin estandarización y con semilla fija, probando cuatro combinaciones de número de árboles y profundidad máxima. La Tabla 9 y la Figura 10 muestran que la mejor configuración, con 100 árboles y profundidad 12, obtuvo un RMSE de validación de Q1,970.59 y un R^2 de 0.534, un 9.9 % menos de error que la regresión lineal y un 31.8 % menos que la referencia. La profundidad influyó mucho más que el número de árboles.

Tabla 9: Configuraciones de Random Forest evaluadas en 2025T4

Árboles	Profundidad	MAE	RMSE	R^2	RMSE entren.	R^2 entren.
50	6	1,155.22	2,138.82	0.4504	2,170.14	0.4425
50	12	1,066.22	1,974.20	0.5318	1,900.10	0.5726
100	6	1,155.27	2,130.07	0.4549	2,162.08	0.4466
100	12	1,064.42	1,970.59	0.5335	1,873.41	0.5845




Figura 10: RMSE de validación por configuración de regresión lineal y de Random Forest, e importancia de las variables en el mejor Random Forest

La ventaja del Random Forest se explica porque la regresión lineal supone efectos aditivos y constantes, mientras que el bosque captura interacciones y umbrales entre la jornada, la educación y la categoría ocupacional. Por eso las horas ganan relevancia en el bosque, con una importancia de 0.117, pese a su baja correlación marginal con el salario. El nivel educativo, con 0.392, y la categoría ocupacional, con 0.264, concentran dos tercios de la importancia. El bosque presenta un sobreajuste moderado, con R^2 de 0.585 en entrenamiento frente a 0.534 en validación, mientras que la regresión lineal no sobreajusta.

7.4. Evaluación final en 2026

Con la configuración elegida de cada algoritmo se reentrenaron los pipelines con todo 2025 y se evaluaron sobre los mismos 13,258 registros de 2026. La Tabla 10 muestra que el Random Forest es el mejor en las tres métricas y reduce el RMSE un 10.3 % y el MAE un 11.9 % frente a la regresión lineal. Ambos modelos se mantuvieron estables respecto de la validación, e incluso mejoraron levemente su R^2 , pese a que el salario medio de 2026 es mayor que el de 2025.

Tabla 10: Métricas en la prueba final de 2026 y comparación con la validación

Modelo	MAE	RMSE	R^2	RMSE valid.	R^2 valid.
Referencia, media de 2025	1,718.09	2,871.42	-0.0025	2,889.57	-0.0031
Regresión lineal	1,240.71	2,163.75	0.4307	2,186.42	0.4257
Random Forest	1,093.57	1,940.30	0.5422	1,970.59	0.5335

8. Análisis de errores

8.1. Salario real frente a predicho y residuos

El residuo se definió como salario real menos salario predicho, por lo que un valor positivo indica subestimación. Las Figuras 11 y 12 usan la misma muestra de 5,000 registros de prueba para ambos modelos. En los dos casos las predicciones se comprimen hacia el centro: quedan por encima de la diagonal en los salarios bajos y por debajo en los altos. La regresión lineal produce algunas predicciones negativas, mientras que el bosque se ajusta mejor en el rango medio. La dispersión de los residuos crece con el salario predicho, lo que indica heterocedasticidad, y la cola de subestimación es más larga que la de sobreestimación.




Figura 11: Salario real frente a salario predicho en 2026 para ambos modelos, misma muestra




Figura 12: Residuos frente al salario predicho en 2026 para ambos modelos, misma muestra

8.2. Error por nivel educativo y por dominio

Las Tablas 11 y 12 se calcularon con todos los registros de prueba. El MAE crece con el nivel educativo porque también crece el salario, y el error medio es pequeño en casi todos los niveles, salvo en doctorado, que ambos modelos subestiman en más de Q5,000 con solo 12 registros. Por dominio, el error relativo es parecido, entre el 30 % y el 37 % del salario medio. El Random Forest obtiene un MAE menor en todos los grupos.

Tabla 11: MAE y error medio por nivel educativo en la prueba de 2026, en quetzales

Nivel educativo	Registros	Salario medio	Regresión lineal		Random Forest	
			MAE	Error medio	MAE	Error medio
Ninguno	1,016	1,884.1	823.5	109.3	640.6	-16.1
Preprimaria	80	2,374.6	735.2	88.8	700.8	-306.4
Primaria	3,957	2,422.7	870.0	54.6	754.5	37.1
Básico	2,164	2,905.5	894.5	127.8	809.8	13.6
Diversificado	4,117	3,924.2	1,109.3	104.0	1,008.5	197.5
Superior	1,729	6,264.4	2,566.4	295.5	2,276.4	278.7
Maestría	183	11,290.6	5,552.9	-131.5	4,601.7	-247.7
Doctorado	12	20,291.7	12,919.3	6,062.7	10,334.8	5,310.1

Tabla 12: MAE y error medio por dominio en la prueba de 2026, en quetzales

Dominio	Registros	Salario medio	Regresión lineal		Random Forest	
			MAE	Error medio	MAE	Error medio
Urbano metropolitano	5,632	4,352.3	1,446.1	136.0	1,298.3	237.2
Resto urbano	4,846	3,281.6	1,189.6	134.3	1,040.7	29.6
Rural nacional	2,780	2,467.7	913.6	65.2	771.0	-11.1

8.3. Error según el percentil del salario

La Tabla 13 y la Figura 13 agrupan los registros de prueba en bandas definidas por percentiles del salario real. El error sigue un patrón monotonico: ambos modelos sobreestiman los salarios bajos, tienen un error medio cercano a cero alrededor de la mediana y subestiman cada vez más los salarios altos. En el 1 % superior, con un salario real medio de Q22,730, la predicción media es de Q8,445 en la regresión lineal y de Q10,398 en el bosque, y todos esos registros quedan subestimados. El 4.85 % de registros con salarios sobre Q8,000 genera el 61.7 % del error cuadrático de la regresión y el 59.4 % del bosque. Las predicciones también son menos dispersas que los datos, con desviaciones estándar de Q1,826 y Q1,912 frente a Q2,868.

Tabla 13: Error medio, MAE y aporte al error cuadrático por banda de percentil del salario real, prueba de 2026

Banda	Registros	Regresión lineal			Random Forest		
		Error medio	MAE	Aporte	Error medio	MAE	Aporte
Hasta p10	1,486	-987	1,070	4.8 %	-873	888	4.0 %
p10 a p25	2,546	-736	956	6.8 %	-694	821	6.4 %
p25 a p50	2,715	-161	852	5.9 %	-177	686	5.0 %
p50 a p75	3,200	-82	833	7.5 %	-41	713	8.8 %
p75 a p90	2,060	493	1,176	7.7 %	516	1,196	9.5 %
p90 a p95	608	1,634	2,076	5.6 %	1,540	1,973	6.7 %
p95 a p99	545	4,092	4,331	20.6 %	3,517	3,805	21.4 %
Sobre p99	98	14,285	14,285	41.1 %	12,332	12,332	38.0 %




Figura 13: Error medio y MAE por banda de percentil del salario real en 2026 para ambos modelos

9. Discusión

Los errores de ambos modelos no son ruido aleatorio alrededor de cero, sino una regresión sistemática hacia la media: se sobreestiman los salarios bajos, se subestiman los altos y el tamaño del error crece con el nivel del salario. La causa principal es que los seis predictores no contienen la información que distingue a quienes ganan mucho, como la ocupación específica, la empresa o el sector de actividad. Personas con el mismo perfil observado tienen salarios muy distintos, y un modelo que minimiza el error cuadrático predice el promedio de ese perfil.

El Random Forest reduce el error en todos los grupos y bandas porque captura interacciones y efectos no lineales, pero conserva el mismo patrón. Los salarios extremos tienen un peso desproporcionado sobre el RMSE, de modo que esta métrica

debe leerse junto con el MAE, que representa mejor el error típico. Los extremos se conservaron como pide el enunciado; modelar el logaritmo del salario o usar pérdidas robustas podría reducir su influencia, pero queda fuera de la comparación obligatoria.

Hay dos limitaciones adicionales. Por el diseño longitudinal, una parte importante de los registros de validación y prueba corresponde a personas ya observadas en entrenamiento, lo que puede hacer las métricas algo optimistas. Además, el análisis es no ponderado y se limita a asalariados con salario positivo, por lo que sus resultados no deben generalizarse a toda la población trabajadora del país.

10. Conclusiones

Los cinco archivos de la ENEIC pudieron integrarse en una base consistente después de resolver tres problemas de origen: una estructura de columnas distinta en IV de 2025, códigos almacenados como texto en II de 2025 y una columna TRIMESTRE que no identifica el trimestre calendario. La población analítica quedó en 53,025 asalariados en 2025 y 13,258 en 2026, con faltantes estructurales y sin claves repetidas.

El salario es muy asimétrico y varía mucho más entre niveles educativos, categorías ocupacionales y dominios que con la edad, la antigüedad o las horas, cuyas correlaciones con el salario no superan 0.18. La segmentación identificó cinco perfiles definidos por la etapa de la trayectoria laboral y la jornada, en los que la jornada parcial y la permanencia prolongada son los rasgos que más cambian el salario típico.

El Random Forest superó a la regresión lineal en validación y en la prueba de 2026, con un R^2 de 0.542 frente a 0.431 y un RMSE 10.3% menor, y ambos modelos mejoraron claramente al modelo de referencia. La regularización no aportó mejoras a la regresión lineal. La principal limitación es la subestimación sistemática de los salarios altos: con los seis predictores disponibles es posible estimar el salario típico de un perfil, pero no el de una persona concreta con precisión.